

PREDICTIVE ANALYTICS: CLASSIFYING BIG MART OUTLET SALES CATEGORY



Anggota Kelompok:

Fellicia Angela Setio - 2802453692

Christian Putra Mahardika - 2802437884

Francis Jordan Hasnawi - 2802412175

Elsa Gabriella - 2802415315

LA01

Data Analytics

**BINUS UNIVERSITY
JAKARTA
2026**

TABLE OF CONTENT

HALAMAN SAMPUL	1
TABLE OF CONTENT	2
Bab 1 INTRODUCTION	3
1.1 Latar Belakang	
Bab 2. LITERATURE REVIEW	5
2.1 Cross-Industry Standard Process for Data Mining	
2.2 Classification	
2.3 Synthetic Minority Over-sampling Technique	
2.4 Categorical Boosting (CatBoost)	
2.5 Hyperparameter Tuning (GridSearchCV)	
2.6 Evaluation Metric	
Bab 3. METHODOLOGY	9
3.1 Business Understanding	
3.2 Data Understanding	
3.3 Data Preparation	
3.4 Modelling	
3.5 Evaluation	
3.6 Deployment	
Bab 4 .IMPLEMENTATION	19
4.1 Proses Pelaksanaan	
4.2 Input Data	
4.3 Data Preprocessing & Cleaning	
4.4 Exploratory Data Analysis (EDA)	
4.5 Modelling	
4.6 Evalution and Result Visualization	
4.7 Deployment	
Bab 5. RESULT AND DISCUSSION	32
5.1 Hasil Kuantitatif	
5.2 Rekomendasi Bisnis	
DAFTAR PUSTAKA	34
LAMPIRAN-LAMPIRAN	35

BAB 1. INTRODUCTION

1.1 Latar Belakang

Industri ritel modern yang bergerak cepat (fast-moving consumer goods atau FMCG) berkembang dengan sangat pesat dan dinamis, menjadikannya salah satu sektor bisnis dengan tingkat persaingan paling ketat saat ini. Dalam ekosistem ritel berskala besar seperti Big Mart yang mengelola ribuan produk di berbagai gerai, keberhasilan operasional sangat ditentukan oleh kemampuan perusahaan dalam memahami perilaku pasar dan mengoptimalkan perputaran barang di setiap cabang. Masalah utama yang sering dihadapi oleh Big Mart adalah fluktuasi volume penjualan yang tidak menentu antar gerai dan jenis produk. Adanya penumpukan stok (overstock) pada produk yang kurang diminati akan membekukan modal kerja dan meningkatkan biaya penyimpanan. Sebaliknya, kelangkaan barang (stockout) pada produk esensial akan menyebabkan hilangnya potensi keuntungan (loss of sales) serta menurunnya kepuasan konsumen. Oleh karena itu, kemampuan untuk memetakan performa penjualan berdasarkan karakteristik unik dari produk serta atribut spesifik dari masing-masing toko menjadi aset strategis yang sangat berharga demi memitigasi ketidakpastian tersebut.

Di sinilah peran penting seorang Data Analyst sekaligus Data Scientist internal, yang bertugas menjembatani tumpukan data transaksi mentah operasional toko dengan kebutuhan strategis manajemen melalui Pengambilan Keputusan Berbasis Data (data-driven decision making). Menggunakan dataset Big Mart Sales yang terdiri dari 8.523 baris data historis dan 12 variabel (mencakup data produk seperti kandungan lemak, visibilitas rak, kategori, harga MRP, hingga karakteristik outlet seperti ukuran dan tipe manajemen), peran analitik awal diwujudkan melalui Exploratory Data Analysis (EDA). Melalui visualisasi deskriptif, ditemukan bahwa terdapat hubungan positif yang kuat (0,57) antara variabel Item_MRP dengan angka penjualan, serta adanya performa superior dari gerai berskala Supermarket Type3. Namun, analisis deskriptif ini belum cukup untuk memitigasi risiko bisnis di masa depan. Oleh karena itu, diperlukan transformasi ke ranah analitik prediktif (predictive analytics) untuk membangun sistem kecerdasan buatan yang mampu mengestimasi performa penjualan secara objektif dan terukur.

Tantangan terbesar dalam mewujudkan proyeksi tersebut adalah realita kualitas data di lapangan yang sering kali "kotor" dan tidak ideal. Berdasarkan analisis kualitas data (Data Quality Assessment) pada dataset Big Mart Sales, ditemukan missing values yang signifikan pada variabel krusial, yaitu ukuran skala toko (Outlet_Size) sebesar 28,27% dan berat produk (Item_Weight) sebesar 17,16%. Selain itu, terdapat inkonsistensi pelabelan data kategorikal pada kadar

lemak produk (Item_Fat_Content seperti teks 'LF', 'low fat', dan 'Low Fat') serta anomali nilai nol pada visibilitas pajangan barang. Masalah teknis ini semakin kompleks karena distribusi data asli penjualan bersifat miring ke kanan secara ekstrem (right-skewed distribution). Ketika data kontinu ini ditransformasikan ke dalam kelas biner, hal tersebut menciptakan ketidakseimbangan kelas (class imbalance) yang parah. Jika data yang cacat dan timpang ini langsung digunakan tanpa penanganan Data Wrangling yang tepat, algoritma prediktif akan menghasilkan output yang bias dan berbahaya jika dijadikan acuan bisnis.

Untuk mengatasi hambatan tersebut, pemanfaatan teknologi Machine Learning hadir sebagai solusi mutakhir melalui tahapan Data Preparation tingkat lanjut menggunakan pustaka Scikit-learn. Proses pembersihan dilakukan dengan memisahkan data (Data Splitting) di awal untuk menghindari kebocoran data (Data Leakage), mengimputasi nilai hilang secara independen, serta menyelaraskan inkonsistensi label. Masalah ketidakseimbangan kelas yang berisiko merusak objektivitas model diselesaikan menggunakan metode Synthetic Minority Over-sampling Technique (SMOTE) untuk menciptakan sampel sintesis baru pada kelas minoritas secara proporsional. Selanjutnya, untuk menghasilkan prediksi yang presisi dan aplikatif, proyek ini mengimplementasikan algoritma klasifikasi CatBoost (Categorical Boosting) yang dikombinasikan dengan GridSearchCV (cv=3) untuk pencarian parameter optimal. CatBoost dipilih karena keunggulan bawaannya dalam menangani fitur kategorikal ritel yang rumit secara otomatis (Ordered Target Statistics) dan struktur puncaknya yang kokoh terhadap risiko overfitting.

Tujuan utama dari proyek analisis ini adalah membangun sebuah sistem model klasifikasi biner yang andal untuk mengelompokkan performa penjualan produk ke dalam kategori High (tinggi) dan Low (rendah) dengan ambang batas nilai 1.500. Melalui pendekatan ini, permasalahan diubah dari estimasi angka kontinu menjadi klasifikasi taktis yang lebih interpretatif bagi pengambilan keputusan bisnis. Hasil akhir yang diharapkan bukan sekadar metrik akurasi di atas kertas, melainkan sebuah peta performa visual dan metrik evaluasi (Confusion Matrix) yang valid secara empiris setelah dilakukan optimasi decision threshold pada angka 0.49 dengan akurasi final 82.93%. Informasi hasil prediksi ini akan berfungsi sebagai instrumen kompas strategis bagi manajemen operasional Big Mart untuk mengoptimalkan strategi inventaris rantai pasok, menentukan pengadaan stok yang efektif di tiap cabang, meminimalisir kerugian finansial, dan mendongkrak profitabilitas perusahaan secara berkelanjutan.

BAB 2. LITERATURE REVIEW

2.1 CRISP-DM (Cross-Industry Standard Process for Data Mining)

Menurut Wirth dan Hipp (2000), CRISP-DM merupakan model proses standar yang komprehensif untuk melaksanakan proyek data mining. Metodologi ini dirancang secara independen agar tidak bergantung pada sektor industri maupun teknologi tertentu, sehingga proyek berskala besar dapat berjalan lebih efisien, andal, dan dapat diulang (repeatable). Siklus hidup proyek data mining dalam kerangka CRISP-DM terdiri dari enam fase utama yang bersifat iteratif (berulang dan tidak harus kaku secara berurutan):

- **Business Understanding:** Memahami tujuan proyek dari sudut pandang bisnis untuk merumuskan definisi masalah data mining.
- **Data Understanding:** Pengumpulan dan eksplorasi awal untuk mengenali karakteristik data serta mengidentifikasi masalah kualitasnya.
- **Data Preparation:** Meliputi seluruh aktivitas pembersihan, konstruksi, dan transformasi untuk menyiapkan dataset akhir dari data mentah.
- **Modeling:** Pemilihan dan penerapan teknik pemodelan beserta kalibrasi parameternya untuk mendapatkan hasil yang optimal.
- **Evaluation:** Evaluasi menyeluruh terhadap model untuk memastikan hasil analisis telah memenuhi kriteria kesuksesan bisnis yang ditetapkan di awal.
- **Deployment:** Penyajian pengetahuan atau model akhir agar dapat diimplementasikan dan dimanfaatkan langsung oleh pengguna.

2.2 Klasifikasi (Classification)

Klasifikasi merupakan salah satu tugas utama dalam supervised learning, yaitu proses pembelajaran mesin di mana model dilatih menggunakan data berlabel untuk memprediksi kategori dari data baru yang belum dikenal. Dalam pendekatan ini, setiap data pelatihan terdiri dari pasangan input dan label kelas yang sesuai, sehingga model dapat mempelajari pola yang membedakan satu kelas dari kelas lainnya (Pedregosa et al., 2011).

Berbagai algoritma klasifikasi telah dikembangkan, masing-masing dengan karakteristik dan keunggulan tersendiri. Pedregosa et al. (2011) mengimplementasikan sejumlah algoritma klasifikasi dalam pustaka Scikit-learn, antara lain Support Vector Machine (SVM), k-Nearest Neighbors (kNN), dan berbagai metode berbasis pohon keputusan. Implementasi algoritma-algoritma tersebut dirancang dengan antarmuka yang konsisten, sehingga memudahkan perbandingan dan pemilihan metode yang paling sesuai untuk suatu permasalahan.

Dalam konteks penelitian ini, klasifikasi digunakan untuk mengelompokkan penjualan produk (Item_Outlet_Sales) ke dalam dua kategori, yaitu Low dan High, berdasarkan ambang batas nilai penjualan 1.500. Pendekatan ini mengubah permasalahan regresi menjadi klasifikasi biner. Transformasi ini dilakukan atas dasar kebutuhan strategis bisnis ritel; memprediksi performa penjualan ke dalam klaster taktis (High vs Low) memberikan tingkat interpretabilitas yang lebih tinggi bagi manajemen dalam mengambil keputusan pengadaan stok barang (inventory control) dibandingkan estimasi angka kontinu yang memiliki varians tinggi.

2.3 SMOTE (Synthetic Minority Over-sampling Technique)

Penelitian oleh Chawla dkk. (2002) memperkenalkan SMOTE (Synthetic Minority Over-sampling Technique) sebagai algoritma inovatif untuk mengatasi kendala ketidakseimbangan kelas (class imbalance) pada dataset. Masalah ketidakseimbangan ini sering ditemukan pada kasus dunia nyata, di mana metrik akurasi standar menjadi tidak relevan karena algoritma cenderung mengabaikan kelas minoritas yang memiliki kepentingan atau biaya salah klasifikasi yang lebih tinggi.

Dibandingkan dengan pendekatan tradisional yang melakukan over-sampling berbasis replikasi (duplikasi sampel dengan pengembalian) yang memicu overfitting dan mempersempit wilayah keputusan (decision regions), SMOTE bekerja dengan menciptakan sampel minoritas baru yang bersifat sintesis. Teknik ini beroperasi di dalam ruang fitur (feature space) dengan cara mengambil selisih antara sampel minoritas yang diamati dan tetangga terdekatnya menggunakan konsep k-nearest neighbors, mengalikannya dengan angka acak antara 0 dan 1, lalu menambahkan hasilnya ke sampel tersebut guna memperluas wilayah keputusan secara umum.

Dalam studinya, metode SMOTE dikombinasikan dengan teknik under-sampling pada kelas mayoritas untuk menyeimbangkan bias algoritma pembelajaran mesin. Hasil eksperimen membuktikan bahwa integrasi SMOTE mendominasi ruang ROC dan menghasilkan performa klasifikasi yang lebih optimal dibandingkan metode undersampling murni. Pada dataset Big Mart Sales, intervensi SMOTE sangat penting guna mencegah model CatBoost bias terhadap kelas mayoritas, sehingga kemampuan model dalam mendeteksi produk-produk potensial yang berkinerja tinggi (High) tetap akurat.

2.4 CatBoost (Categorical Boosting)

CatBoost merupakan algoritma gradient boosting berbasis pohon keputusan yang dikembangkan untuk mengatasi masalah prediction shift dan

target leakage yang umum terjadi pada algoritma GBDT konvensional (Prokhorenkova et al., 2018). Keunggulan utama CatBoost terletak pada kemampuannya menangani fitur kategorikal secara otomatis melalui teknik Ordered Target Statistics (TS). Teknik ini mengubah nilai kategori menjadi fitur numerik dengan mempertimbangkan urutan acak data untuk mencegah kebocoran informasi dari label target.

Dalam konteks dataset ritel Big Mart yang memiliki banyak variabel kategorikal seperti Item_Fat_Content, Item_Type, dan Outlet_Type, CatBoost tetap menjadi pilihan yang relevan dibandingkan algoritma boosting lainnya seperti XGBoost dan LightGBM. Meskipun pada implementasi penelitian ini fitur kategorikal telah melalui proses encoding pada tahap preprocessing, CatBoost tetap menunjukkan keunggulan dalam mempelajari hubungan kompleks antara fitur numerik dan kategorikal secara stabil. Dibandingkan XGBoost yang lebih rentan mengalami overfitting pada konfigurasi tertentu dan LightGBM yang lebih berfokus pada efisiensi serta kecepatan pelatihan, CatBoost menawarkan keseimbangan yang baik antara akurasi, stabilitas model, dan kemampuan generalisasi.

Selain itu, CatBoost menerapkan mekanisme Ordered Boosting untuk menghasilkan estimasi gradien yang lebih tidak bias selama proses iterasi. Algoritma ini juga menggunakan struktur Oblivious Decision Trees (pohon keputusan pelupa), di mana kriteria pemisahan (splitting) yang sama diterapkan pada seluruh level pohon. Struktur yang simetris ini membantu mengurangi risiko overfitting sekaligus menjaga efisiensi komputasi saat proses prediksi berlangsung. Karakteristik tersebut menjadikan CatBoost sesuai untuk digunakan pada model klasifikasi penjualan ritel yang memiliki variasi pola data cukup kompleks pada fitur produk maupun atribut toko.

2.5 Hyperparameter Tuning (GridSearchCV)

Hyperparameter tuning merupakan proses krusial untuk mencari kombinasi nilai parameter optimal sebelum pelatihan model dimulai demi memaksimalkan performa generalisasinya. Salah satu metode yang paling umum digunakan adalah GridSearchCV (Grid Search Cross-Validation), yang bekerja secara menyeluruh (exhaustive) mengevaluasi setiap kemungkinan kombinasi dari ruang pencarian hiperparameter yang telah ditentukan sebelumnya. Dengan mengintegrasikan cross-validation, metode ini mampu memastikan bahwa performa model yang diukur lebih stabil, objektif, dan tidak bias terhadap satu partisi data saja.

Meskipun Bergstra & Bengio (2012) mencatat bahwa Grid Search memiliki kelemahan efisiensi berupa curse of dimensionality ketika ruang parameternya terlalu besar, metode ini tetap menjadi standar industri untuk

penyetelan halus (fine-tuning) pada ruang parameter yang terfokus. Dalam implementasinya, GridSearchCV diterapkan pada model CatBoostClassifier dengan melisensikan parameter perputaran cross-validation sebesar cv=3. Langkah ini menguji kombinasi parameter internal seperti iterations, learning_rate, dan depth, sehingga berhasil menemukan konfigurasi terbaik yang menghasilkan akurasi paling optimal pada data latih tanpa mengorbankan kemampuan generalisasi pada data uji.

2.6. Evaluation Metric

Evaluasi performa model klasifikasi dilakukan untuk mengukur seberapa baik model dalam mengidentifikasi kelas-kelas yang ada secara objektif. Dasar utama dari evaluasi ini adalah Confusion Matrix, yang terdiri dari empat nilai utama: True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN). Berdasarkan nilai-nilai tersebut, beberapa metrik standar digunakan untuk menilai efektivitas model (Sokolova & Lapalme, 2009):

- **Accuracy:** Mengukur efektivitas keseluruhan dari sebuah pengklasifikasi dalam memprediksi seluruh kelas secara tepat.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision:** Menggambarkan tingkat kesesuaian antara label data asli dengan label positif yang diberikan oleh model. Metrik ini krusial untuk meminimalkan False Positive (produk yang diprediksi High namun aslinya Low, yang berisiko memicu pemborosan modal akibat penumpukan stok).

$$Precision = \frac{TP}{TP + FP}$$

- **Recall (Sensitivity):** Menilai efektivitas model dalam mengidentifikasi seluruh label positif yang ada dalam data. Metrik ini krusial untuk meminimalkan False Negative (produk High yang diprediksi Low, yang berisiko menyebabkan stockout dan hilangnya potensi keuntungan).


$$Recall = \frac{TP}{TP + FN}$$

- **F1-score:** Merupakan kombinasi harmonik antara Precision dan Recall yang memberikan gambaran performa model yang seimbang, terutama ketika menangani dataset yang mengalami ketidakseimbangan kelas seperti kasus Big Mart Sales ini.

$$F1Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

BAB 3. METHODOLOGY

Proses Data Science



3.1 Business Understanding

Penelitian ini bertujuan untuk memprediksi performa penjualan produk di berbagai gerai (outlets) Big Mart secara akurat. Fokus utama dari proyek analisis data ini adalah memahami faktor-faktor penentu yang mempengaruhi volume penjualan, baik dari karakteristik produk (seperti berat, kadar lemak, dan visibilitas area pajang) maupun atribut spesifik gerai (seperti ukuran toko, tipe lokasi kota, dan usia operasional gerai).

Melalui pemahaman pola historis ini, permasalahan diubah dari estimasi angka kontinu (regresi) yang memiliki varians tinggi menjadi klasifikasi biner taktis (High vs Low). Dengan transformasi ini, perusahaan ritel diharapkan dapat mengambil keputusan bisnis yang lebih interpretatif dan strategis, mengoptimalkan manajemen inventaris rantai pasok, meminimalisir risiko kerugian operasional akibat overstock maupun stockout, serta meningkatkan profitabilitas perusahaan secara berkelanjutan.

3.2 Data Understanding

Tahap ini dilakukan untuk mengenali karakteristik dasar, struktur, serta tingkat higienitas dataset melalui eksplorasi awal secara terprogram. Eksplorasi dijalankan pada dataset Big Mart Sales yang memiliki volume data sebesar 8.523 baris dan 12 kolom variabel, yang terdiri dari kombinasi tipe data numerik (float64 sebanyak 4 kolom, int64 sebanyak 1 kolom) dan objek/kategorikal (object sebanyak 7 kolom). Berdasarkan hasil audit data menggunakan fungsi `df.info()`, `df.describe()`, dan pengujian logika Python di Google Colab, ditemukan 5 anomali kualitas data (Data Quality Audit) utama pada data mentah yang wajib diintervensi pada tahap preparasi data berikutnya:

- **Masalah Nilai Kosong (Missing Values)**

Pengecekan menggunakan fungsi `.isnull().sum()` mendeteksi adanya kekosongan data pada dua fitur krusial secara masif, yaitu:

- **Variabel Outlet_Size (kategori skala ukuran toko):** Memiliki missing values sebanyak 2.410 baris atau sebesar 28,27% dari total dataset.
- **Variabel Item_Weight (berat fisik produk):** Memiliki missing values sebanyak 1.463 baris atau sebesar 17,16% dari total dataset.
- Sementara itu, 10 variabel lainnya terkonfirmasi bersih (0% missing values).

- **Masalah Nilai Nol Tidak Valid (Zero Values Anomaly)**

Pada pengujian logika variabel Item_Visibility (persentase luas area pajang produk), ditemukan sebanyak 526 baris data bernilai tepat 0.000000. Secara operasional bisnis ritel, nilai ini dinilai cacat atau tidak valid, karena produk yang sukses dipajang dan mencatatkan transaksi penjualan di kasir tidak mungkin memiliki persentase visibilitas nol persen di rakMasalah toko.

- **Kebersihan Label Kategorikal (Categorical Inconsistency)**

Pengecekan sebaran nilai unik pada fitur Item_Fat_Content (kadar lemak) menunjukkan adanya redundansi penulisan teks untuk kategori yang sama. Kategori produk rendah lemak ditulis terpecah menggunakan string 'Low Fat', 'low fat', dan 'LF', sedangkan produk lemak normal ditulis terpecah menggunakan string 'Regular' dan 'reg'.

- **Deteksi Nilai Ekstrem (Outlier Analysis via Boxplot)**

Melalui visualisasi diagram kotak garis (boxplot) menggunakan pustaka Seaborn, distribusi sebaran data numerik dianalisis menggunakan metode Interquartile Range (IQR). Ditemukan adanya titik-titik data pencilan (outliers) yang berkerumun padat di atas batas maksimum (upper bound) pada variabel Item_Visibility (di atas nilai 0,20) dan variabel target Item_Outlet_Sales (berkerumun dari rentang 6.000 hingga melebihi 12.000). Sebaran outlier pada variabel target ini mengonfirmasi sifat distribusi data penjualan asli ritel yang miring ke kanan (right-skewed distribution).

- **Pemeriksaan Data Duplikat (Duplicate Rows Check)**

Pengujian menggunakan fungsi `df.duplicated().sum()` menghasilkan nilai 0. Hal ini menegaskan bahwa tidak ada polusi data berupa replikasi baris yang sama persis di dalam dataset ini, sehingga seluruh 8.523 baris bersifat unik dan valid untuk masuk ke tahap pemodelan.

3.3 Data Preparation

Tahap ini merupakan proses krusial untuk mentransformasikan data mentah yang dinilai "kotor" pada fase Data Understanding menjadi dataset final yang higienis, valid, dan siap diproses oleh algoritma machine learning. Seluruh proses manipulasi data dilakukan secara terpisah antara data latih (training set) dan data uji (testing set) untuk menjamin sterilisasi informasi dan menghindari bias kebocoran data (data leakage). Langkah-langkah preprocessing yang diimplementasikan adalah sebagai berikut:

- **Pengelompokan Target & Pemisahan Data (Target Binning & Data Splitting)**

Sebelum melakukan imputasi, variabel target kontinu Item_Outlet_Sales ditransformasikan terlebih dahulu menjadi variabel kategorikal biner, yaitu kelas 'Low' (jika nilai penjualan < 1.500) dan kelas 'High' (jika nilai penjualan ≥ 1.500). Setelah itu, dataset yang memiliki total 8.523 baris langsung dipisahkan menggunakan fungsi `train_test_split` dari library Scikit-Learn dengan proporsi rasio 80:20. Langkah ini menghasilkan 6.818 baris untuk data latihan (X_train) dan 1.705 baris untuk data uji (X_test).

- **Pembersihan Nilai Kosong (Handling Missing Values)**

Identifikasi awal menunjukkan adanya data kosong pada kolom Outlet_Size (28,27%) dan Item_Weight (17,16%).

- **Variabel Item_Weight:** Dari total 1.463 baris yang kosong pada dataset awal, terdapat 1.174 baris kosong yang berada di dalam data latihan. Penanganan nilai kosong ini dilakukan secara bertahap: pertama, diisi menggunakan nilai rata-rata (mean) berat produk berdasarkan kesamaan kode unik Item_Identifier.

Jika masih terdapat sisa nilai kosong, sistem akan mengisinya menggunakan nilai rata-rata berdasarkan rumpun kategori makro Item_Type. Langkah terakhir, jika masih ada sisa, diisi dengan nilai rata-rata global Item_Weight dari data train.

- **Variabel Outlet_Size:** Dari total 2.410 baris kosong pada dataset awal, terdapat 1.932 baris kosong yang berada di dalam data latihan. Penanganan dilakukan menggunakan tabel kontingensi (pivot table), di mana nilai kosong diimputasi menggunakan nilai modus (nilai yang paling sering muncul) dari variabel Outlet_Size yang dikelompokkan secara spesifik berdasarkan format operasional Outlet_Type terkait.

- **Penanganan Nilai Nol Tidak Valid (Handling Zero Values)**

Anomali nilai 0.0 pada fitur Item_Visibility (luas area pajang produk) terdeteksi sebanyak 526 baris (422 baris pada data latihan dan 104 baris pada data uji). Karena secara logika produk yang sukses terjual tidak mungkin memiliki persentase visibilitas nol persen di rak toko, nilai anomali ini diubah terlebih dahulu menjadi missing value (NaN), lalu diimputasi menggunakan nilai rata-rata visibilitas produk berdasarkan kelompok Item_Type yang dihitung dari data latihan.

- **Penanganan Inkonsistensi (Handling Inconsistencies)**

Redundansi penulisan data pada fitur Item_Fat_Content disatukan menggunakan fungsi .replace(). Label yang tumpang tindih seperti 'LF' dan 'low fat' diselaraskan menjadi 'Low Fat', sedangkan label 'reg' diselaraskan menjadi 'Regular'.

- **Rekayasa Fitur (Feature Engineering):**

- **Pembuatan Fitur Item_Category:** Mengekstraksi dua karakter alfabet pertama dari kode Item_Identifier untuk memetakan rumpun besar produk menjadi tiga kategori utama, yaitu: 'FD' (Food), 'DR' (Drinks), dan 'NC' (Non-Consumable).
- **Logika Batasan Bisnis Kategori:** Khusus untuk produk yang masuk ke dalam klaster 'NC' (Non-Consumable), label kadar lemak pada variabel Item_Fat_Content secara otomatis dialihkan menjadi kategori baru yaitu 'Non-Edible'. Langkah ini diambil atas dasar logika operasional ritel, mengingat produk non-konsumsi tidak memiliki kandungan nutrisi lemak.
- **Pembuatan Fitur Outlet_Years:** Menghitung durasi usia operasional gerai ritel dengan mencari selisih antara tahun batas penarikan data historis (2013) dengan tahun berdirinya toko (Outlet_Establishment_Year).

- **Reduksi Kolom dan Transformasi Numerik (Feature Drop & One-Hot Encoding):**

- **Penyaringan Kolom:** Menghapus variabel independen yang memiliki kardinalitas terlalu tinggi dan tidak memiliki korelasi langsung terhadap performa penjualan, yaitu kolom Item_Identifier, Outlet_Identifier, dan Outlet_Establishment_Year.
- **Representasi Numerik (Encoding):** Mengubah seluruh fitur kategorikal tekstual yang tersisa menjadi bentuk matriks biner

numerik menggunakan metode One-Hot Encoding via fungsi `pd.get_dummies()` dengan opsi `drop_first=True` untuk menghindari jebakan multikolinieritas (dummy variable trap).

- **Penyelarasan Dimensi (Feature Alignment):** Untuk memastikan jumlah dan urutan kolom antara data latihan dan data uji tetap identik setelah proses encoding, diterapkan fungsi `.align(join='left', axis=1, fill_value=0)`.

- **Standardisasi Skala Fitur Numerik (*Feature Scaling*)**

Mengingat fitur-fitur numerik memiliki rentang nilai yang sangat berbeda, diterapkan algoritma `StandardScaler` untuk menyamakan skala data (nilai rata-rata menjadi 0 dan standar deviasi menjadi 1). Objek scaler dihitung konfigurasinya menggunakan fungsi `.fit_transform()` eksklusif pada data latihan, sedangkan untuk data uji murni hanya diaplikasikan menggunakan fungsi `.transform()`.

- **Penanganan Ketidakseimbangan Kelas (*Handling Class Imbalance via SMOTE*)**

Berdasarkan analisis distribusi data latihan, ditemukan adanya ketidakseimbangan kelas (class imbalance) di mana jumlah sampel kategori 'High' lebih mendominasi dibandingkan kategori 'Low'. Untuk mengatasi bias model, metode SMOTE (Synthetic Minority Over-sampling Technique) diimplementasikan hanya pada data latihan.

Melalui algoritma pembentukan sampel sintetis ini, data latihan yang semula berjumlah 6.818 baris, berhasil diseimbangkan menjadi total 7.910 baris. Dataset latihan baru tersebut kini memiliki proporsi yang seimbang secara proporsional, yaitu masing-masing 3.955 baris untuk kelas 'Low' dan 3.955 baris untuk kelas 'High', sehingga telah siap 100% untuk masuk ke tahap pemodelan `CatBoost`.

3.4 Modelling

Tahap pemodelan (modeling) difokuskan untuk membangun arsitektur model klasifikasi biner yang mampu mengidentifikasi performa penjualan produk secara akurat. Penjualan dikelompokkan menjadi dua kategori strategis, yaitu kelas 'Low' (untuk nilai penjualan di bawah 1.500) dan kelas 'High' (untuk nilai penjualan 1.500 ke atas) berdasarkan kombinasi karakteristik fitur produk serta atribut toko.

Dalam penelitian ini, algoritma CatBoost Classifier dipilih sebagai model utama berdasarkan beberapa pertimbangan teknis dan karakteristik dataset Big Mart Sales yang didominasi oleh fitur-fitur kategorikal (high-cardinality features) namun juga masih memiliki fitur-fitur numerikal. Berikut adalah beberapa justifikasi ilmiah pemilihan CatBoost:

- **Penanganan Fitur Kategorikal yang Unggul (Ordered Target Statistics)**

Dataset Big Mart memiliki banyak variabel teks penting (seperti Item_Type, Outlet_Type, dll.). Algoritma Gradient Boosting lain seperti XGBoost umumnya memerlukan penanganan fitur kategorikal yang lebih kompleks pada tahap preprocessing, sedangkan CatBoost memang dirancang untuk menangani fitur kategorikal secara lebih efektif dibandingkan banyak algoritma boosting lainnya. CatBoost juga memiliki mekanisme internal yang baik dalam mempelajari hubungan antara fitur numerik dan kategorikal sehingga dapat menghasilkan model yang lebih stabil.

- **Pencegahan Kebocoran Data (Unbiased Ordered Boosting)**

CatBoost menerapkan metode permutasi acak dalam menghitung nilai gradien pada tiap iterasi. Hal ini mencegah terjadinya prediction shift dan target leakage (kebocoran target), sehingga model yang dihasilkan jauh lebih stabil saat diuji pada data baru (test set).

- **Struktur Pohon yang Seimbang (Oblivious Trees)**

CatBoost menggunakan Oblivious Decision Trees, di mana kriteria pemisahan (splitting) yang sama diterapkan di seluruh level pohon. Struktur yang simetris ini bertindak sebagai regulator alami yang meminimalisir risiko overfitting sekaligus mempercepat waktu komputasi saat model melakukan prediksi.

Proses pembangunan model dijalankan secara sistematis melalui rangkaian tahapan berikut:

- **Penanganan Ketidakseimbangan Data (SMOTE Implementation):**

Berdasarkan pemeriksaan distribusi pada data latihan, ditemukan ketimpangan jumlah data antara kelas 'Low' dan 'High'. Untuk mengatasinya, teknik SMOTE (Synthetic Minority Over-sampling Technique) diterapkan khusus pada data latihan. Melalui algoritma ini, kelas minoritas ('Low') ditambah menggunakan data sintesis baru hingga

jumlahnya seimbang 50:50 dengan kelas mayoritas, menghasilkan total 7.910 baris data latihan baru yang siap digunakan untuk proses modeling.

- **Pembangunan Model Awal (Baseline CatBoost Model):**

Sebelum melakukan optimasi parameter, model CatBoost Classifier dasar dibangun terlebih dahulu sebagai acuan performa awal (baseline score). Model ini dilatih menggunakan data training yang telah melalui tahapan preperation, standardisasi fitur, serta penyeimbangan distribusi kelas menggunakan SMOTE. Model baseline ini bertujuan untuk memperoleh gambaran performa awal CatBoost sebelum dilakukan proses tuning parameter. Hasil evaluasi model baseline kemudian digunakan sebagai pembandingan untuk mengukur efektivitas proses optimasi yang dilakukan pada tahap berikutnya.

- **Optimasi Parameter Menggunakan Grid Search (Hyperparameter Tuning):**

Untuk mencari kombinasi parameter terbaik yang dapat menghasilkan performa generalisasi paling optimal, diterapkan metode GridSearchCV dari pustaka Scikit-Learn. Proses pencarian ini diintegrasikan dengan mekanisme Cross-Validation sebanyak 3 perputaran (cv=3) guna menghindari bias pada satu partisi data latihan saja. Ruang parameter (hyperparameter space) yang diuji pada algoritma CatBoost meliputi:

- Jumlah pohon keputusan (iterations): [100, 300, 500]
- Tingkat pembelajaran (learning_rate): [0.01, 0.05, 0.1]
- Kedalaman maksimum pohon (depth): [4, 6, 8]

- **Pemodelan Akhir Berbasis Parameter Optimal (Final Modeling After Tuning):**

Setelah mengevaluasi seluruh kombinasi ruang parameter secara menyeluruh (exhaustive search), GridSearchCV berhasil menyaring kombinasi parameter terbaik (best parameters), yaitu: **depth: 6, iterations: 100, dan learning_rate: 0.05**. Kombinasi parameter juara inilah yang kemudian dikunci dan digunakan sebagai konfigurasi akhir model CatBoost Classifier yang kemudian diterapkan pada proses prediksi dan evaluasi.

- **Penyesuaian Batas Keputusan (Custom Decision Threshold):**

Secara bawaan (default), model klasifikasi menggunakan ambang batas keputusan (decision threshold) pada angka 0.50 untuk memisahkan kelas.

Namun, untuk memperoleh konfigurasi klasifikasi yang memberikan performa evaluasi terbaik pada data uji, kelompok kami melakukan optimasi batas ambang. Melalui pemanfaatan fungsi nilai probabilitas `.predict_proba()`, batas keputusan digeser sedikit ke angka 0.49. Setiap produk yang memiliki skor probabilitas ≥ 0.49 secara otomatis akan diklasifikasikan ke dalam performa penjualan 'High', sedangkan di bawah nilai tersebut diklasifikasikan sebagai 'Low'.

3.5 Evaluation

Tahap evaluasi dilakukan untuk mengukur sejauh mana model CatBoost Classifier yang telah dioptimalkan mampu mengklasifikasikan performa penjualan pada data uji secara objektif dan akurat. Rangkaian proses evaluasi dirancang sebagai berikut:

- **Metrik Evaluasi Klasifikasi Berbasis Confusion Matrix**

Kinerja model diukur secara kuantitatif dengan menguji data prediksi terhadap data aktual pada data uji (test set). Metrik utama yang digunakan murni merupakan metrik evaluasi klasifikasi biner, yang meliputi:

- **Accuracy:** Mengukur persentase ketepatan model dalam memprediksi seluruh kelas (baik 'High' maupun 'Low') secara global.
- **Precision:** Mengukur kemampuan model dalam menekan tingkat salah tebak pada kelas positif (meminimalisir produk yang diprediksi High padahal aslinya Low demi mencegah pemborosan modal akibat penumpukan stok).
- **Recall (Sensitivity):** Mengukur jangkauan model dalam mendeteksi seluruh data aktual kelas positif (meminimalisir produk High yang terlewat dan diprediksi Low demi menghindari fenomena kelangkaan barang/stockout).
- **F1-Score:** Nilai rata-rata harmonik yang menyeimbangkan metrik Precision dan Recall sebagai indikator utama stabilitas model.

- **Perancangan Evaluasi Komparatif Visual (Multi-Panel Plot)**

Untuk memetakan performa klasifikasi model secara makro dan mikro pada data uji, penelitian ini mengimplementasikan visualisasi grafis dua panel berdampingan (side-by-side bar chart):

- **Panel Kiri - Distribusi Agregat (Actual vs Predicted):**
Membandingkan total volume data asli di lapangan dengan total volume data hasil tebakan model CatBoost secara keseluruhan. Visualisasi ini dirancang untuk mendeteksi kecenderungan sifat model secara global (apakah model cenderung bersikap optimis/overpredict atau pesimis/underpredict terhadap suatu kelas).
- **Panel Kanan - Proporsi Benar-Salah per Kelas Aktual:**
Membedakan ketepatan tebakan model secara spesifik pada masing-masing kelompok kelas target riilnya. Visualisasi ini mengekstrak persentase keandalan Recall model dalam mengenali mana tebakan yang benaran akurat (Correct) dan mana tebakan yang meleset (Incorrect) pada tiap-tiap kelas tanpa terdistorsi oleh total volume data makro.

- **Output Utama**

Luaran akhir dari tahap evaluasi ini adalah laporan metrik performa (classification report) yang valid secara empiris serta peta visualisasi performa model. Output ini digunakan sebagai basis analisis kekuatan prediksi sebelum model dikunci untuk masuk ke tahap deployment di web dashboard, sekaligus menjadi landasan operasional bagi manajemen dalam menyusun strategi pengadaan barang di toko.

3.6 Deployment

- **Arsitektur Deployment Berbasis ONNX (Client-Side Inference Architecture)**

Tahap akhir dari kerangka kerja CRISP-DM adalah pengerahan model (deployment) ke dalam lingkungan produksi agar dapat dimanfaatkan oleh pengguna akhir secara riil. Penelitian ini merancang arsitektur deployment modern berbasis Client-Side Inference menggunakan standar format ONNX (Open Neural Network Exchange). Pendekatan ini dipilih karena mampu mengonversi model CatBoost Classifier yang kompleks menjadi sebuah format portabel yang ringan, sehingga proses komputasi prediksi dapat dieksekusi langsung di dalam browser pengguna tanpa memerlukan server backend atau API gateway tambahan.

- **Komponen Pendukung Arsitektur Sistem**

Rancangan arsitektur deployment ini terdiri dari empat komponen data esensial yang saling terintegrasi:

- **Model ONNX Core (model.onnx):** Hasil serialisasi dan konversi arsitektur pohon keputusan model CatBoost Classifier ke dalam representasi format ONNX.
- **Metadata Skema (model_schema.json & model_manifest.json):** Berkas konfigurasi yang memetakan struktur tipe data input, nama-nama kolom prediktor, serta aturan skalabilitas fitur.
- **Pemetaan Label (label_mapping.json):** Berkas kamus untuk menerjemahkan output numerik hasil prediksi biner kembali menjadi representasi teks kategorikal (High/Low Sales).
- **Antarmuka Pengguna (template.html / index.html):** Halaman web interaktif berbasis HTML dan JavaScript yang memuat runtime ONNX untuk mengumpulkan input dari pengguna dan menampilkan visualisasi hasil proyeksi penjualan secara instan.

BAB 4. IMPLEMENTASI

4.1 Proses Pelaksanaan

Penelitian ini dilakukan untuk mengoptimalkan efisiensi strategi pengadaan stok ritel dan prediksi performa penjualan gerai melalui pemanfaatan analisis data historis. Proses implementasi secara teknis dibagi menjadi beberapa tahapan utama yang terstruktur, meliputi: tahap penyediaan input data, pemisahan data (train-test split), pelaksanaan data preprocessing & cleaning pada masing-masing partisi, proses exploratory data analysis (EDA) berbasis visualisasi, pemodelan data, serta tahap evaluasi hasil performa prediksi.

4.2 Input Data

Tahap awal pelaksanaan dimulai dengan mengintegrasikan dataset retail Big Mart yang memuat data riil transaksi penjualan sebanyak 8.523 baris dan 12 kolom. Atribut penyusun dataset ini mencakup kode unik produk (Item_Identifier), berat produk (Item_Weight), kadar lemak (Item_Fat_Content), visibilitas display (Item_Visibility), kategori produk (Item_Type), harga maksimal (Item_MRP), identitas gerai (Outlet_Identifier), tahun berdiri (Outlet_Establishment_Year), ukuran gerai (Outlet_Size), tipe lokasi kota (Outlet_Location_Type), jenis format toko (Outlet_Type), dan total penjualan sebagai target utama (Item_Outlet_Sales). Dataset ini menjadi pondasi tunggal bagi seluruh proses analisis dan pengerjaan berikutnya.

4.3 Data Preprocessing & Cleaning

Tahap preprocessing dilaksanakan secara ketat untuk menanggulangi anomali kualitas data mentah agar dataset menjadi bersih dan terstandarisasi sebelum dialirkan ke algoritma. Untuk mencegah kebocoran data (data leakage), dataset biner disisihkan terlebih dahulu dengan rasio 80:20 menjadi 6.818 baris data latihan dan 1.705 baris data uji, di mana kalkulasi statistik preprocessing di data latihan akan menjadi acuan bagi data uji.

- **Imputasi Nilai Hilang (Missing Values)**

Berdasarkan pengecekan awal pada data latihan (terdapat 1.174 baris kosong pada Item_Weight dan 1.932 baris kosong pada Outlet_Size), pembersihan dilakukan secara bertahap. Kolom Item_Weight diisi menggunakan nilai rata-rata (mean) dari kelompok kode unik Item_Identifier yang sama, lalu dilanjutkan berdasarkan kelompok Item_Type jika masih ada yang kosong. Sementara itu, baris kosong pada Outlet_Size diisi menggunakan nilai modus dari tabel kontingensi yang dikelompokkan spesifik berdasarkan variabel Outlet_Type. Hasil akhir

menunjukkan tingkat kebersihan data latihan dan uji mencapai 100% tanpa nilai null yang tersisa.

- **Standardisasi Data Kategorikal**

Mengatasi variasi penulisan yang inkonsisten pada kolom Item_Fat_Content. Dilakukan proses penyeragaman makro (mapping) menggunakan fungsi .replace() di mana label 'LF', 'low fat', dan 'Low Fat' disatukan menjadi label standar 'Low Fat', sedangkan label 'reg' dan 'Regular' dilebur menjadi 'Regular'.

- **Koreksi Logika Parameter (Handling Zero Values)**

Memperbaiki nilai anomali 0.0 pada variabel Item_Visibility (terdapat 422 data kosong di data latihan dan 104 data di data uji). Nilai nol tersebut diubah menjadi NaN lalu diimputasi dengan nilai rata-rata (mean) dari visibilitas display produk berdasarkan kelompok Item_Type sejenis dari data latihan, karena secara operasional fisik toko tidak mungkin ada barang pajangan ritel yang memiliki persentase ruang 0%.

- **Feature Engineering & Transformation:**


Menambahkan fitur baru bernama Outlet_Years yang mengekstrak nilai selisih waktu dari tahun batas atas data (2013) dikurangi tahun pendirian gerai (Outlet_Establishment_Year).

- Membuat variabel Item_Category yang memetakan dua huruf awal dari Item_Identifier menjadi tiga kelompok makro: Food (FD), Drink (DR), dan Non-Consumable (NC).
- Logika Batasan Bisnis: Khusus untuk produk yang masuk kelompok 'NC' (Non-Consumable), label kadar lemak pada variabel Item_Fat_Content secara otomatis dialihkan menjadi kategori baru yaitu 'Non-Edible' karena produk non-konsumsi secara logis tidak memiliki kandungan nutrisi lemak.

4.4 Exploratory Data Analysis (EDA)

Setelah dataset dipastikan bersih dari anomali, dilakukan proses Exploratory Data Analysis (EDA) pada data latihan untuk menangkap pola perilaku bisnis, korelasi antar variabel, serta karakteristik distribusi performa penjualan gerai.


- **Distribution of Item Outlet Sales**



Penjelasan Gambar: Grafik histogram di atas menampilkan bentuk sebaran data variabel target `Item_Outlet_Sales` yang memiliki pola miring ke kanan secara ekstrem (right-skewed distribution). Kepadatan transaksi terbesar berada pada rentang omset rendah hingga menengah, yaitu antara kisaran nilai 0 hingga 2.000. Frekuensi sebaran data terlihat terus menurun secara drastis seiring meningkatnya nilai penjualan di atas rentang angka 6.000.

Justifikasi Bisnis & Teknis: Pola asimetris ini memberikan landasan empiris yang kuat bagi penetapan batas ambang (threshold) klasifikasi sebesar 1.500 untuk memisahkan performa kelas transaksi Low dan High. Ketimpangan sebaran ini juga menjadi justifikasi logis di tahapan lanjut untuk menggunakan algoritma penyeimbang data seperti SMOTE agar model prediktif tidak mengalami bias akibat dominasi data kelas rendah.


- **Correlation Matrix**



Penjelasan Gambar: Visualisasi heatmap ini digunakan untuk menganalisis arah dan kekuatan hubungan linear antar variabel numerik di dalam dataset ritel. Berdasarkan matriks koefisien yang terbentuk, variabel Item_MRP (harga eceran maksimal) menunjukkan nilai korelasi positif paling dominan dan signifikan terhadap total penjualan (Item_Outlet_Sales) dengan skor sebesar 0,57.

Justifikasi Bisnis & Teknis: Angka korelasi 0,57 membuktikan secara valid bahwa faktor harga barang bertindak sebagai prediktor linear paling kuat terhadap tinggi rendahnya nilai omset penjualan dibanding parameter numerik lainnya. Sebaliknya, parameter Item_Visibility memperlihatkan korelasi negatif lemah (-0,13), sementara Item_Weight (0,01) dan Outlet_Establishment_Year (-0,05) bernilai mendekati nol yang menandakan absennya hubungan linear langsung. Hal ini mendasari keputusan seleksi fitur penting dalam pemodelan.

- **Sales Distribution by Outlet Type**




Penjelasan Gambar: Grafik boxplot di atas memetakan variabilitas distribusi omset penjualan berdasarkan karakteristik kategorikal tipe format toko (Outlet_Type). Hasil visualisasi memperlihatkan bahwa kelompok format Supermarket Type3 menempati posisi puncak dengan capaian nilai median serta rentang interkuartil (IQR) tertinggi dibanding ketiga jenis format gerai lainnya.

Justifikasi Bisnis & Teknis: Capaian distribusi pada Supermarket Type3 menunjukkan bahwa karakteristik operasional pada tipe toko tersebut secara konsisten menghasilkan volume penjualan yang jauh lebih

menguntungkan. Sebaliknya, format Grocery Store memiliki kotak sebaran penjualan yang sangat sempit dan tertekan di bawah nilai 2.000. Perbedaan pola visual yang tajam ini mengonfirmasi status variabel Outlet_Type sebagai fitur pembeda (discriminative feature) yang sangat kaya informasi untuk disertakan ke dalam model.

- **Hubungan MRP vs Sales (Scatter Plot)**



Penjelasan Gambar: Grafik scatter plot ini memetakan persebaran titik data koordinat antara variabel Item_MRP pada sumbu horizontal (X) dengan Item_Outlet_Sales pada sumbu vertikal (Y) untuk mendalami temuan korelasi kualitatif sebelumnya. Terlihat pembentukan tren positif yang konsisten, di mana batas atas sebaran poin penjualan ritel bergerak naik secara linier searah meningkatnya harga produk.

Justifikasi Bisnis & Teknis: Pola persebaran data secara visual memperlihatkan adanya fenomena pengelompokan vertikal (structured vertical clustering). Pada kelompok produk dengan harga murah (MRP di bawah 70), sebaran titik data sangat rapat dan hampir tidak pernah menembus angka penjualan 4.000. Sementara itu, produk berkategori premium (MRP di atas 200) memiliki sebaran titik yang sangat variatif dengan potensi lonjakan nilai penjualan yang tinggi hingga mencapai puncaknya di atas 12.000. Pola sebaran ini memperkuat alasan teoritis mengapa variabilitas harga menjadi pendorong utama variabilitas omset penjualan.

4.5 Pemodelan (Modeling)

Untuk tahap pemodelan ini, variabel target yang digunakan adalah Item_Outlet_Sales yang telah ditransformasikan menjadi bentuk kategorikal biner,

yaitu kelas 'Low' dan 'High'. Kategori Low ditetapkan untuk nilai penjualan di bawah 1.500, sedangkan kategori High untuk nilai penjualan yang sama dengan atau lebih besar dari 1.500. Penggunaan batas ambang (threshold) 1.500 ini diselaraskan secara konsisten dengan justifikasi bisnis pada tahapan sebelumnya.

- **Implementasi Penyeimbangan Data (SMOTE):**

Condition	“High”	“Low”	Total Baris
Before SMOTE	3.955	2.863	6.818
After SMOTE	3.955	3.955	7.910

Hasil pemeriksaan sebaran distribusi pada data latihan asli menunjukkan adanya ketimpangan (imbalance), di mana kategori 'High' bertindak sebagai kelas mayoritas dengan total 3.955 data, sedangkan kategori 'Low' bertindak sebagai kelas minoritas dengan total 2.863 data.

Untuk mengeliminasi bias prediksi model agar tidak hanya sensitif terhadap transaksi bernilai tinggi, metode SMOTE (Synthetic Minority Oversampling Technique) diterapkan khusus pada data latihan untuk menghasilkan sampel sintesis baru pada kelas minoritas (Low). Setelah SMOTE dieksekusi, jumlah data pada kedua kategori menjadi seimbang sempurna, masing-masing menyentuh angka 3.955 data (dengan akumulasi total data latih pasca-SMOTE menjadi 7.910 baris). Dengan kondisi data latihan yang seimbang ini, model dipastikan dapat mempelajari karakteristik produk beromset rendah maupun tinggi secara adil dan objektif.

- **Pembangunan Model Dasar (Baseline Model)**

Pemodelan awal diimplementasikan menggunakan algoritma CatBoost Classifier. Pemilihan algoritma ini didasari oleh keunggulannya dalam menangani hubungan non-linear antar fitur, serta performanya yang sangat stabil saat memproses dataset ritel yang mengombinasikan tipe data numerik dan kategorikal berdimensi tinggi. Sebagai acuan performa awal (baseline), model dilatih di atas data latihan hasil SMOTE menggunakan konfigurasi parameter bawaan (default), dari CatBoost Classifier dengan `random_state=42` dan `verbose=0` untuk menjaga konsistensi eksperimen.

- **Optimasi Parameter Menggunakan Grid Search (Hyperparameter Tuning)**

Untuk meningkatkan performa, akurasi dan kemampuan generalisasi model pada data uji, diterapkan metode GridSearchCV yang diintegrasikan dengan 3-Fold Cross-Validation (cv=3). Langkah ini menguji berbagai kombinasi parameter penting pada CatBoost, meliputi kedalaman pohon (depth: [4, 6, 8]), jumlah pohon (iterations: [100, 300, 500]), dan tingkat pembelajaran (learning_rate: [0.01, 0.05, 0.1]). Berdasarkan hasil pencarian menyeluruh (exhaustive search), sistem berhasil mengunci kombinasi parameter terbaik (best parameters), yaitu: **depth: 6, iterations: 100, dan learning_rate: 0.05.**

- **Pemodelan Akhir (Final CatBoost Model + Custom Threshold)**

Pada tahap pemodelan akhir digunakan model CatBoost dengan kombinasi parameter optimal hasil tuning (depth=8, iterations=500, learning_rate=0.01) yang diperoleh melalui proses Grid Search. Tidak hanya itu, untuk memperoleh konfigurasi klasifikasi yang memberikan performa evaluasi terbaik pada data pengujian (testing set), dilakukan penyesuaian batas keputusan (decision threshold) menggunakan fungsi probabilitas .predict_proba(), di mana ambang batas digeser sedikit dari nilai bawaan 0.50 menjadi 0.49.

4.6 Evaluasi dan Visualisasi Hasil

Evaluasi akhir diimplementasikan dengan menguji performa model pada data uji (test set) yang berisi 1.705 baris data. Untuk mengupas tuntas perbandingan performa secara adil pada masing-masing kelas target (High dan Low) sebelum dan setelah proses optimasi dilakukan, berikut adalah ringkasan metrik dari classification report riil hasil eksperimen:

- **Kinerja Model Sebelum Optimasi (Baseline Model)**

Berikut adalah hasil pencatatan performa model CatBoost dasar yang berjalan dengan parameter default (verbose=0, random_state=42) dan threshold standar 0.50:

Target Kelas & Nilai Rata-rata	Precision	Recall	F1-Score
Kelas High (Sales >= 1500)	0.81	0.89	0.85
Kelas Low (Sales < 1500)	0.84	0.75	0.79
Macro Average	0.83	0.82	0.82

Weighted Average	0.83	0.83	0.82
------------------	------	------	------

Analisis Temuan Model Baseline: Berdasarkan hasil evaluasi diatas, model baseline sudah dapat mengklasifikasikan kategori penjualan dengan cukup baik dengan akurasi sebesar **82,52%**. Nilai precision, recall, dan F1-score pada kedua kelas juga menunjukkan performa yang relatif seimbang. Hasil ini menunjukkan bahwa model awal sudah memiliki kemampuan klasifikasi yang baik dan layak digunakan sebagai acuan sebelum dilakukan proses optimasi.

- **Kinerja Model Setelah Optimasi (Model Final)**

Berikut adalah hasil pencatatan metrik evaluasi model CatBoost final setelah menerapkan parameter terbaik hasil Grid Search (depth=6, iterations=100, learning_rate=0.05) beserta custom threshold 0.49


Target Kelas & Nilai Rata-rata	Precision	Recall	F1-Score
Kelas High (Sales >= 1500)	0.82	0.90	0.85
Kelas Low (Sales < 1500)	0.85	0.75	0.80
Macro Average	0.83	0.82	0.83
Weighted Average	0.83	0.83	0.83

Analisis Temuan Model Final: Setelah dilakukan penyesuaian parameter dan pergeseran ambang batas (Tabel 4.3), performa model akhir mengalami peningkatan. Nilai Global Accuracy merangkak naik menjadi **82.99%**, terjadi peningkatan sebesar **0.47%** dibandingkan model baseline.

Nilai precision pada kedua kategori juga mengalami peningkatan dibandingkan model baseline. Peningkatan ini menunjukkan bahwa proses hyperparameter tuning dan penyesuaian threshold memberikan dampak positif terhadap performa model. Selain itu, nilai precision, recall, dan F1-score pada kedua kategori tetap menunjukkan performa yang baik dan relatif seimbang. Secara keseluruhan, model setelah tuning mampu memberikan hasil klasifikasi yang sedikit lebih baik dibandingkan model baseline sehingga dipilih sebagai model akhir pada penelitian ini.

- **Analisis Visualisasi Performa Model Final**

Untuk memperkuat pembuktian performa model final secara visual, hasil komparatif dianalisis menggunakan grafik dua panel berdampingan (Multi-Panel Plot) pada data uji.



1. Pembacaan Panel Kiri - Distribusi Akumulatif Data (Actual vs Predicted):

Grafik batang pertama membandingkan total volume data aktual (biru) dengan data hasil prediksi model (oranye). Berdasarkan data aktual pada data uji, kelas High memiliki total 947 data dan kelas Low memiliki 758 data. Hasil prediksi model setelah pergeseran threshold mengubah distribusi volume global ini menjadi 1.041 data untuk kelas High dan 664 data untuk kelas Low.


Justifikasi Bisnis & Teknis: Selisih angka nominal ini mengonfirmasi adanya kecenderungan overpredicting pada kelas High (+94 data) dan underpredicting pada kelas Low (-94 data). Secara bisnis ritel, karakteristik model CatBoost ini memiliki kecenderungan bersikap lebih "optimis" dengan memproyeksikan total volume transaksi penjualan tinggi yang sedikit lebih besar dari kondisi riil di lapangan.

2. Pembacaan Panel Kanan - Proporsi Benar-Salah per Kelas Aktual:

Grafik batang kedua memetakan persentase ketepatan tebakan model secara spesifik langsung di dalam masing-masing kelas target aslinya. Visualisasi ini membuktikan bahwa persentase warna batang Correct (Tebakan Benar) mendominasi secara mutlak di kedua kelas, baik pada produk yang aslinya berkinerja High maupun Low. Hal ini merepresentasikan tingkat keandalan prediksi model yang tidak hanya tinggi secara agregat global, melainkan juga konsisten saat diuji secara mikro pada masing-masing kelas target.

- Analisis Evaluasi Komprehensif Berbasis Multi-Panel Plot

Untuk memvalidasi keandalan model final secara menyeluruh dari berbagai sudut pandang metrik data sains, proses evaluasi akhir dilengkapi dengan visualisasi makro berbentuk Multi-Panel Plot. Kompilasi grafik ini menyatukan visualisasi metrik biner, kurva diskriminasi, hingga analisis kontribusi fitur ke dalam satu kesatuan dashboard evaluasi.



1. Analisis Matriks Kebingungan (Confusion Matrix & Heatmap Report):

Berdasarkan panel Confusion Matrix (kiri atas) dan Classification Report (kanan atas), model berhasil mengklasifikasikan sebagian besar produk pada kategori penjualan tinggi (High) dengan baik. Dari total 947 data aktual kategori High, sebanyak 849 data berhasil diprediksi dengan benar sebagai High, sedangkan 98 data lainnya diprediksi sebagai Low. Sementara itu, dari 758 data aktual kategori Low, model berhasil mengidentifikasi 566 data secara tepat sebagai Low, sedangkan 192 data lainnya diprediksi sebagai High. Nilai precision, recall, dan F1-score menunjukkan performa yang cukup baik pada kedua kategori.

Justifikasi Bisnis & Teknis: Hasil recall kategori High yang mencapai 0,9 menunjukkan bahwa model mampu mengidentifikasi sebagian besar produk dengan performa penjualan tinggi secara tepat. Kemampuan ini dapat membantu pihak manajemen dalam mengenali produk yang berpotensi memiliki tingkat penjualan tinggi sehingga dapat digunakan sebagai bahan pertimbangan dalam perencanaan stok dan strategi penjualan.

2. Analisis Kemampuan Diskriminasi Model (ROC Curve & Precision-Recall Curve):

Visualisasi pada panel baris kedua menampilkan performa pemisahan kelas yang sangat objektif. Grafik ROC Curve menghasilkan skor AUC sebesar 0.905 (jauh melampaui garis acuan acak 0.50), didukung oleh grafik Precision-Recall Curve yang mencatatkan nilai Average Precision (AP) sebesar 0.912 (di atas garis baseline default 0.56).

Justifikasi Bisnis & Teknis: Nilai AUC dan AP yang sukses menembus angka di atas 0.90 ini secara ilmiah membuktikan bahwa model CatBoost final memiliki stabilitas dan akurasi yang superior dalam memisahkan karakteristik produk berkinerja High maupun Low, sehingga sangat valid untuk dijadikan alat bantu pengambilan keputusan manajemen.

3. Analisis Faktor Penentu Penjualan (Feature Importance):

Visualisasi Feature Importance menunjukkan bahwa variabel **Outlet_Type_Supermarket_Type1** merupakan faktor yang paling berpengaruh dalam proses prediksi dengan kontribusi sekitar **36,2%**. Faktor ini kemudian diikuti oleh **Outlet_Size_Medium** sebesar **18,8%**, **Item_MRP** sebesar **18,1%**, **Outlet_Size_Small** sebesar **10,8%**, dan **Outlet_Years** sebesar **5,5%**.

Justifikasi Bisnis & Teknis: Hasil ini menunjukkan bahwa karakteristik toko dan atribut produk memiliki pengaruh yang besar terhadap performa penjualan. Tipe gerai, ukuran outlet, serta harga produk menjadi faktor utama yang dipertimbangkan model dalam menentukan kategori penjualan. Temuan ini dapat digunakan sebagai dasar dalam penyusunan strategi bisnis dan pengelolaan produk pada tahap rekomendasi berikutnya.

4.7 Deployment

Single Prediction

Item Weight

Item Fat Content

Item Visibility

Item Type

Item MRP

Outlet Size

Outlet Location Type

Outlet Type

Item Category

Outlet Years

Predict

LOW SALES

High: 19.4% | Low: 80.6%

a. Proses Eksekusi dan Serialisasi Model ke ONNX

Proses *deployment* diawali dengan menginstalasi pustaka pendukung onnx. Setelah model utama dilatih, arsitektur model diekspor secara native ke dalam bentuk berkas biner teroptimasi bernama model.onnx. Bersamaan dengan pembuatan model tersebut, sistem secara otomatis mengekstrak parameter masukan dan memetakan label ke dalam tiga berkas konfigurasi terpisah, yaitu model_schema.json untuk validasi tipe fitur, model_manifest.json untuk arsitektur metadata, dan label_mapping.json untuk kamus konversi hasil kelas keluaran. Keempat komponen berkas ini kemudian dienkapsulasi dan diinjeksikan secara terintegrasi ke dalam berkas antarmuka akhir bernama template.html (yang menghasilkan output aplikasi web terkompilasi dashboard.html sebesar 1,9 MB).

b. Analisis Hasil Alur Kerja Penyaluran (*Deployment*)

Berdasarkan visualisasi arsitektur sistem pada gambar serta hasil kompilasi skrip pada berkas notebook, uji coba fungsionalitas sistem berbasis *client-side runtime* ini berhasil dijalankan dengan performa yang sangat efisien.

- **Penjelasan Proses Arsitektur:** Alur kerja sistem berjalan secara lokal di dalam peramban web (*browser*) pengguna. Ketika

pengguna memasukkan parameter spesifikasi produk ritel dan karakteristik toko pada halaman antarmuka web, JavaScript di sisi klien menangkap data tersebut dan menyelaraskannya berdasarkan cetak biru aturan di `model_schema.json`. Selanjutnya, data input dialirkan ke dalam mesin *ONNX Runtime* yang tertanam pada halaman web untuk dievaluasi langsung oleh file objek `model.onnx`. Hasil inferensi biner yang dikeluarkan model kemudian diterjemahkan oleh `label_mapping.json` untuk menampilkan visualisasi teks status akhir prediksi penjualan (*High Sales* atau *Low Sales*) kepada pengguna secara *real-time*.

- **Justifikasi Bisnis & Teknis:** Implementasi pengerahan model menggunakan arsitektur *ONNX client-side* ini memberikan keuntungan teknis dan efisiensi biaya yang sangat masif bagi perusahaan ritel. Karena seluruh proses kalkulasi komputasi prediksi dipindahkan dari server ke komputer atau perangkat *gadget* milik pengguna (*client-side*), perusahaan tidak perlu mengeluarkan biaya investasi untuk menyewa server komputasi berspesifikasi tinggi (*cloud computing cost*) ataupun mengelola pemeliharaan infrastruktur *Backend API gateway* yang rumit. Sistem ini juga memiliki keunggulan berupa latensi nol karena tidak membutuhkan proses pengiriman data bolak-balik melalui jaringan internet, serta menjamin privasi data operasional ritel yang dimasukkan pengguna tetap aman di dalam perangkat mereka sendiri.

BAB 5. HASIL & DISKUSI

5.1 Hasil Kuantitatif

Pengujian akhir model **CatBoost Classifier** pada data uji (*test set*) dilakukan untuk mengevaluasi kemampuan generalisasi model dalam mengklasifikasikan performa penjualan menjadi dua kelas biner taktis: **High Sales** (> 1.500) dan **Low Sales** (< 1.500). Rangkuman metrik evaluasi kuantitatif disajikan pada Tabel 5.1.

Kelas Target	Sampel Aktual	Prediksi Benar	Prediksi Salah
High Sales	947	849	98
Low Sales	758	565	193

Tabel 5.1 Rangkuman Metrik Evaluasi Kuantitatif CatBoost Classifier

Berdasarkan data kuantitatif pada Tabel 5.1, analisis performa model disimpulkan sebagai berikut:

1. **Akurasi Global:** Model membukukan akurasi sebesar 82,9%, menunjukkan bahwa sebagian besar data transaksi ritel berhasil diprediksi secara tepat.
1. **Sensitivitas Tinggi (High Sales):** Model sangat andal dalam mendeteksi gerai/produk berpotensi omset tinggi dengan nilai *Recall* mencapai 89,7% dan *F1-Score* sebesar 85,4%.
2. **Karakteristik Low Sales:** Model menghasilkan *Precision* yang kuat di angka 85,2%. Nilai *Recall* sebesar 75% menunjukkan model sedikit "optimis", di mana beberapa transaksi bernilai rendah diproyeksikan sebagai kelas *High* (*False Positive*).

Secara akumulatif, model memprediksi 1.042 data sebagai kelas *High* dan 663 data sebagai kelas *Low*. Hasil ini membuktikan stabilitas algoritma CatBoost dalam memitigasi varians tinggi dari model regresi konvensional.

5.2 Rekomendasi Bisnis

Berdasarkan temuan eksplorasi data (EDA) dan implementasi aplikasi web ONNX Client-Side, berikut adalah rekomendasi bisnis strategis bagi manajemen Big Mart:

1. Strategi Harga Dinamis berbasis Segmentasi MRP Fitur Item_MRP terbukti menjadi prediktor paling dominan (korelasi 0,57). Manajemen harus menerapkan strategi pemasaran terpisah. Untuk kluster produk

premium ($MRP > 200$), gunakan program loyalitas dan *bundling* untuk menjaga stabilitas transaksi. Untuk produk murah ($MRP < 70$), fokus pada kecepatan perputaran volume barang melalui promo kuantitas (misal: *buy 2 get 1*).

2. Alokasi Inventaris berdasarkan Format Toko Hasil analisis menunjukkan Supermarket Type3 secara konsisten menghasilkan median penjualan tertinggi, sedangkan Grocery Store berada di posisi terendah. Pasokan produk baru dan premium harus diprioritaskan ke *Supermarket Type3*, sementara *Grocery Store* harus menerapkan *lean inventory* (hanya menyuplai kebutuhan pokok esensial) demi menekan biaya penyimpanan gudang (*holding cost*).
3. Pemanfaatan Aplikasi ONNX Web untuk Operasional Ritel Aplikasi web berbasis HTML tunggal (index.html sebesar 979 KB) dapat didistribusikan langsung kepada manajer gerai di lapangan. Karena komputasi berjalan di sisi klien (*client-side*), perusahaan dapat memotong biaya sewa server (*cloud cost*) secara masif. Manajer toko dapat melakukan simulasi stok secara mandiri; jika sistem memprediksi *High Sales*, stok dapat ditambah dengan percaya diri, dan jika diprediksi *Low Sales*, pengadaan barang dapat dibatasi secara preventif untuk mencegah kerugian akibat *overstock*.

DAFTAR PUSTAKA

- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a Standard Process Model for Data Mining. *DaimlerChrysler Research & Technology and Wilhelm-Schickard-Institute, University of Tübingen*.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2019). CatBoost: unbiased boosting with categorical features. *arXiv preprint arXiv:1706.09516* <https://doi.org/10.48550/arXiv.1706.09516>
- Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13(1), 281–305.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing and Management*, 45(4), 427-437. <https://doi.org/10.1016/j.ipm.2009.03.002>

LAMPIRAN

Link collab: ->

<https://colab.research.google.com/drive/14Vr4b3rzM0jITcYMP1TawQtc2UWJ1g3I#scrollTo=Cht3vBkjNJle>

Link dataset ->

https://drive.google.com/drive/folders/1bpDQMXB1f3cOIxOszqI_X3OIRzQU4nfj?usp=sharing